Trabajo Práctico - Procesamiento de Lenguaje Natural

Ciencia de Datos

Lectura recomendada: https://web.stanford.edu/ jurafsky/slp3/15.pdf

Asociación de palabras[1]

- 1. Levantar el corpus AP, separando cada noticia como un elemento distinto en un diccionario (<DOCNO> : <TEXT>).
- 2. Calcular el tamaño del vocabulario.
- Para las 500 palabras con más apariciones, calcular el par más asociado según la medida presentada.

Información Léxica[2]

Bajar de Project Gutenberg el libro de Darwin \it{ON} \it{THE} \it{ORIGIN} \it{OF} $\it{SPE-CIES}$.

- 1. Procesar el texto, tokenizando eliminando signos de puntuación.
- 2. Siguiendo el artículo de la sección, calcular la autocorrelación para estimar la distribución de la palabra a lo largo del texto.
- 3. Calcular la entropía de una selección de 100 palabras que abarquen el rango de frecuencia de aparición en el libro, es decir elegir palabras que son muy frecuentes y otras de baja frecuencia.
- Calcular la entropía de las palabras seleccionadas anteriormente, randomizando su posición en el texto. Comparar con los resultados del punto anterior.

Word embeddings, distancia semántica y Word-Net

- 1. Utilizando el test WordSim 353^1 , comparar el rendimiento entre LSA[3] y Word2Vec²[4].
- 2. Comparar los distintos word embeddings con las medidas definidas en WordNet.

http://alfonseca.org/eng/research/wordsim353.html

²Ver pre-trained word vectors en https://code.google.com/archive/p/word2vec/

Referencias

- [1] Kenneth Ward Church and Patrick Hanks. Word association norms, mutual information, and lexicography. *Computational linguistics*, 16(1):22–29, 1990.
- [2] Marcelo A Montemurro and Damián H Zanette. Towards the quantification of the semantic information encoded in written language. *Advances in Complex Systems*, 13(02):135–153, 2010.
- [3] Thomas K Landauer. Latent semantic analysis. Wiley Online Library, 2006.
- [4] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeff Dean. Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems*, pages 3111–3119, 2013.